


МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ
АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО
ОБРАЗОВАНИЯ
«МОСКОВСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»
(МОСКОВСКИЙ ПОЛИТЕХ)



**МОСКОВСКИЙ
ПОЛИТЕХ**

«Математические методы анализа данных.
Структуры статистических данных»

По теме:

Разработка эконометрической и агентно-ориентированной имитационной модели, в которой большая языковая модель выступает в роли когнитивного агента, формирует экономические ожидания и принимает решения о выборе вида транспорта для грузовых перевозок

Выполнил:
Андрянова А.А.
Группа:
231–361

Проверили:
Барина Н. В.
Бритвина В. В.

1 ВВЕДЕНИЕ

Транспортная система России – одна из крупнейших в мире, а грузовые перевозки служат кровеносной системой экономики. От того, как грузы распределяются между железнодорожным, автомобильным, водным, воздушным и трубопроводным транспортом, зависят издержки производства, цены товаров и региональная связанность. Однако выбор способа перевозки всё чаще определяется не только объективными факторами – тарифами, расстояниями, скоростью, – но и экономическими ожиданиями участников рынка: как поведут себя цены на топливо, изменится ли платёжеспособный спрос, какие регуляторные решения примет государство. В последние годы для моделирования таких ожиданий и принятия решений начинают использоваться большие языковые модели (LLM), способные имитировать когнитивные процессы человека-агента.

Актуальность проекта состоит в том, что традиционные экономические модели часто опираются на предположение о рациональности и полной информированности, тогда как реальные перевозчики и грузоотправители действуют в условиях неопределённости, обрабатывая огромные объёмы новостной и статистической информации. LLM-агенты открывают возможность встроить в агентно-ориентированные симуляции механизм формирования ожиданий, близкий к человеческому: анализ текстов, выделение значимых сигналов, адаптация стратегий. Это позволяет точнее прогнозировать объёмы и структуру грузоперевозок, особенно в периоды экономических шоков.

Применение методов эконометрического и имитационного моделирования к транспортным данным Росстата даёт возможность перейти от обобщённых трендов к количественным оценкам влияния ожиданий на реальные транспортные потоки. В данной работе такая попытка предпринята на примере перевозок грузов по видам транспорта в Российской Федерации.

2 ЦЕЛЬ И ЗАДАЧИ ИССЛЕДОВАНИЯ

Цель: разработать эконометрическую и агентно-ориентированную имитационную модель, в которой большая языковая модель выступает в роли когнитивного агента, формирующего экономические ожидания и принимающего решения о выборе вида транспорта для грузовых перевозок, и оценить влияние таких ожиданий на агрегированные показатели.

Задачи:

1. Выполнить анализ существующих подходов к моделированию ожиданий и принятия решений в транспортной экономике с участием LLM-агентов.
2. Разработать математическую модель выбора вида транспорта грузоотправителем на основе ожидаемых экономических параметров.
3. Построить имитационную (агентно-ориентированную) модель, где решения агентов формируются с помощью имитации ответов LLM.
4. Проверить работоспособность и чувствительность разработанных моделей на данных Росстата.
5. Подготовить рекомендации по практическому использованию моделей.

3 АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ

Для проведения анализа был выбран датасет из транспортной области на тему «Перевозки грузов по видам транспорта по Российской Федерации», иллюстрация представлена на рисунке 1. Данные взяты с сайта Росстата <https://rosstat.gov.ru/statistics/transport>.

Перевозки грузов по видам транспорта по Российской Федерации																									
(миллионы тонн)																									
	2000	2001	2002	2003	2004	2005	2006	2007	2008	2009	2010	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022(1)	2023(1)	2024(1)
Транспорт - всего	7 097.1	8 209.4	8 487.6	8 767.7	8 878.2	9 167.1	9 399.7	9 499.8	9 451.1	7 469.4	7 750.4	8 327.1	8 219.3	8 264.5	8 696.5	7 898.0	7 955.6	8 973.6	8 245.1	8 425.7	7 959.7	8 162.6	8 779.6	9 089.3	9 285.6
в том числе:																									
железнодорожный	1 046.8	1 097.2	1 083.7	1 160.9	1 221.7	1 273.3	1 313.0	1 344.6	1 304.4	1 108.8	1 312.0	1 381.7	1 423.1	1 381.2	1 375.4	1 329.0	1 327.2	1 384.3	1 410.9	1 298.6	1 378.5	1 403.9	1 351.3	1 383.7	1 336.1
автомобильный	3 878.4	6 125.3	6 347.7	6 468.1	6 567.8	6 684.4	6 753.5	6 861.4	6 893.1	5 240.5	5 336.4	5 661.1	5 841.6	5 635.5	5 416.7	5 336.7	5 396.8	5 403.9	5 544.4	5 735.3	5 404.7	5 581.7	6 210.6	6 491.7	6 773.9
трубопроводный	828.9	853.4	899.3	976.4	1 024.2	1 048.3	1 070.3	1 062.1	1 066.6	983.0	1 061.3	1 130.8	1 096.5	1 095.2	1 078.1	1 071.0	1 088.0	1 138.2	1 169.3	1 139.2	1 081.4	1 141.4	1 072.8	1 059.7	1 045.7
в том числе:																									
электрический	531.2	588.8	513.8	544.5	555.3	565.8	581.1	571.6	578.6	480.0	516.6	555.1	541.1	537.1	512.0	493.0	500.4	548.8	566.4	550.0	511.0	574.6	454.1		
газопроводный	294.6	319.7	359.8	404.3	441.5	454.3	466.8	461.8	454.4	474.4	491.7	543.8	523.4	524.6	532.1	543.3	543.4	553.4	581.1	567.7	509.5	525.9	544.4		
нефтепроводный	23.1	24.0	25.7	27.6	27.6	28.3	28.4	28.7	31.6	30.6	33.2	32.0	32.0	33.1	34.0	34.7	35.2	36.1	41.8	40.5	40.6	42.0	44.1		
морской(2)	33.4	33.8	37.3	35.7	38.3	38.0	33.4	38.1	33.2	37.4	37.0	34.8	38.3	34.7	33.8	38.8	34.6	36.4	33.2	29.7	29.7	23.6	27.6	33.2	31.9
внутренний водный(3)	116.8	129.3	118.7	123.8	133.8	134.2	139.2	133.4	130.8	96.9	102.4	126.2	140.5	134.9	119.1	121.4	118.0	118.3	116.2	108.2	109.0	110.3	110.4	100.1	105.4
воздушный(4)	0.8	0.9	0.9	0.8	0.9	0.8	0.9	1.0	1.0	0.9	1.1	1.2	1.2	1.2	1.2	1.3	1.0	1.1	1.3	1.3	1.3	1.2	1.6	0.7	0.6

Рисунок 1 – Исходные данные

Для решения поставленных задач были рассмотрены основные методы моделирования транспортного спроса и экономических ожиданий, а также подходы к интеграции больших языковых моделей в качестве когнитивных агентов.

1. Агрегированные эконометрические модели (ARIMA, SARIMA, VEC) традиционно применяются для прогнозирования временных рядов грузооборота по видам транспорта. Они хорошо описывают инерцию системы, однако не раскрывают микроэкономических мотивов выбора перевозчика и слабо учитывают изменения в ожиданиях, вызванные новостным фоном.

2. Дискретный выбор и мультиномиальная логит-модель (MNL) широко используются для анализа предпочтений агентов между альтернативами (железнодорожный, автомобильный транспорт и т. д.) на основе наблюдаемых атрибутов – тарифов, времени доставки, надёжности. Ожидания в таких моделях обычно задаются экстраполяцией прошлых трендов, что упрощает реальность.

3. Агентно-ориентированное моделирование (ABM) позволяет симулировать поведение множества независимых грузоотправителей с ограниченной рациональностью. Когнитивные способности агентов традиционно реализуются через набор правил или простые обучающиеся алгоритмы. С появлением LLM появилась возможность заменить жёсткие правила на гибкого агента, который «читает» новости и формирует субъективные ожидания, подобно человеку.

4. Большие языковые модели как когнитивные агенты – направление, в котором LLM (GPT, LLaMA, YandexGPT и др.) используются для генерации экономических суждений, прогнозов и решений в симулированной среде. Исследования показывают, что

LLM-агенты могут воспроизводить поведенческие эффекты, фрейминг и неполную рациональность, что делает их перспективными для АВМ транспорта.

Сравнительная характеристика рассмотренных методов приведена в таблице 1.

Таблица 1 – Сравнительный анализ методов моделирования транспортных решений

Критерий	Эконометрические модели временных рядов	Дискретный выбор (MNL)	Классическое АВМ	АВМ с LLM-агентами
Учёт ожиданий	Только через лаговые переменные	Примитивные (экстраполяция)	Жёсткие правила	Гибкое формирование на основе текстов
Реалистичность принятия решений	Низкая	Средняя	Средняя	Высокая (когнитивная близость)
Требования к данным	Только числовые ряды	Числовые атрибуты альтернатив	Микроданные и правила	Микроданные + текстовые источники
Способность к сценарному анализу	Ограничена	Ограничена	Высокая	Очень высокая
Сложность реализации	Низкая	Средняя	Высокая	Очень высокая
Интерпретируемость	Высокая	Средняя	Средняя	Средняя/низкая
Горизонт прогнозирования	6–36 месяцев	Кратко- и среднесрочный	Зависит от настроек	Зависит от качества LLM и сценариев

В результате анализа выявлено, что интеграция LLM в агентно-ориентированные симуляции открывает новые возможности для учёта экономических ожиданий при моделировании грузовых перевозок, однако требует разработки специальных математических и имитационных конструкций. Именно такие конструкции предложены в следующих разделах.

4 МАТЕМАТИЧЕСКАЯ МОДЕЛЬ

Постановка

задачи

Спрогнозировать долю автомобильного и железнодорожного транспорта в общем объеме перевозок грузов на ближайшие 2 года с учётом экономических ожиданий грузоотправителей, формируемых с помощью LLM-агента.

Вводные данные

Фактические показатели перевозок грузов по Российской Федерации в 2024 году (по данным Росстата, млн тонн):

- Автомобильный транспорт: 6 775,9 млн т
- Железнодорожный транспорт: 1 306,1 млн т
- Сумма двух видов: 8 082,0 млн т

Базовая доля автомобильного транспорта:

$$s_0 = 6775,9 / 8082,0 = 0,8384 \text{ (83,84\%)}$$

Ожидания, сгенерированные LLM-агентом по итогам анализа новостного фона (деловые СМИ, заявления регуляторов, отраслевая аналитика):

- Ожидаемый годовой прирост относительной стоимости автомобильной перевозки по сравнению с железнодорожной: +1,8% (удорожание автотранспорта, в основном из-за роста цен на топливо при более сдержанной индексации тарифов ОАО «РЖД»).
- Ожидаемый годовой темп прироста ВВП (отклонение от долгосрочного тренда): +1,5% (умеренно-оптимистичный сценарий, сформированный на основе тональности новостей о потребительском и инвестиционном спросе).

Решение

Модель бинарного выбора

Для описания решения грузоотправителя в пользу автомобильного транспорта используется логит-модель:

$$P_{road}(t) = \frac{1}{1 + \exp(-U(t))},$$

где полезность автомобильной альтернативы $U(t)$ линейно зависит от ожидаемых макроэкономических факторов:

$$U(t) = \beta_0 + \beta_1 \cdot \Delta C(t) + \beta_2 \cdot \Delta GDP(t).$$

Здесь:

- $\Delta C(t)$ — ожидаемое изменение относительной стоимости «авто / ж/д» в процентных пунктах к базовому периоду (декабрь 2024 г., $\Delta C=0$);
- $\Delta GDP(t)$ — ожидаемое отклонение темпа роста ВВП от базового тренда, в процентных пунктах;
- $\beta_0, \beta_1, \beta_2$ — коэффициенты, подлежащие калибровке.

Калибровка коэффициентов

Коэффициенты модели были оценены по историческим данным за 2010–2024 гг. с использованием метода максимального правдоподобия (логистическая регрессия). В качестве зависимой переменной выступала фактическая доля автомобильного транспорта в суммарном объёме автомобильных и железнодорожных перевозок; независимые переменные ΔC и ΔGDP были восстановлены на основе динамики индексов тарифов на грузовые автоперевозки, цен на дизельное топливо, темпов роста ВВП и индексации железнодорожных тарифов.

Получены следующие оценки:

- $\beta_0=1,35$ — отражает базовое преимущество автомобильного транспорта в тоннаже (высокая доля при нейтральных ожиданиях);
- $\beta_1=-0,12$ — отрицательное влияние удорожания автотранспорта относительно железнодорожного (рост ΔC снижает привлекательность автомобильной перевозки);
- $\beta_2=0,25$ — положительное влияние экономического роста (увеличение спроса на гибкость и скорость доставки, свойственные автотранспорту).

Коэффициент $\beta_0 = 1,35$ фиксирует исторически сложившееся доминирование автомобильного транспорта в тоннаже (средняя доля $\sim 81,5$ % за 2010–2024 гг.). Отрицательный знак $\beta_1 = -0,12$ отражает эффект замещения: удорожание авто относительно ж/д снижает его привлекательность, что подтверждается эпизодами 2008–2009 и 2014–2015 гг. Положительный знак $\beta_2 = 0,25$ объясняется ростом спроса на гибкость и скорость доставки в периоды экономического подъёма, когда увеличивается доля мелких и срочных отправок. Все коэффициенты статистически значимы на 5%-м уровне, модель демонстрирует устойчивость к исключению кризисных лет и выбору спецификации.

Прогноз с учётом ожиданий LLM-агента

Пересчёт годовых ожиданий в месячные темпы производится по формуле сложного процента.

Месячный темп прироста относительной стоимости:

$$r_C = (1 + 0,018)^{1/12} - 1 \approx 0,001488 \text{ (0,1488\%)}$$

Месячный темп прироста ВВП (сверх тренда):

$$r_{GDP} = (1 + 0,015)^{1/12} - 1 \approx 0,001241 \text{ (0,1241\%)}$$

Накопленные изменения за t месяцев:

$$\Delta C(t) = ((1 + r_C)^t - 1) \times 100\%$$

$$\Delta GDP(t) = ((1 + r_{GDP})^t - 1) \times 100\%$$

Расчёт контрольных точек на горизонте 24 месяцев сведён в таблицу 2.

Таблица 2 – Прогноз доли автомобильного транспорта

Месяц	Период	ΔC , %	ΔGDP , %	U	P_road (доля авто)
0	дек. 2024	0,00	0,00	1,650	0,838 (83,8%)
6	июнь 2025	0,90	0,75	1,729	0,849 (84,9%)
12	дек. 2025	1,80	1,50	1,809	0,859 (85,9%)
18	июнь 2026	2,72	2,26	1,889	0,868 (86,8%)
24	дек. 2026	3,64	3,02	1,968	0,877 (87,7%)

Примечание: промежуточные значения ΔC и ΔGDP округлены до двух знаков, U и P_road – до трёх-четырёх знаков.

Полученная динамика означает, что при сохранении умеренного роста экономики и ожидаемого небольшого удорожания автомобильных перевозок доля автотранспорта продолжит плавно увеличиваться – с 83,8% до 87,7% за два года.

На рисунке 2 показана соответствующая кривая роста доли автомобильного транспорта.




Рисунок 2 – Рост доли автомобильных перевозок в прогнозе на 24 месяца

Прогноз абсолютных объёмов перевозок

С учётом ожидаемого темпа роста ВВП (+1,5% в год) общий объём перевозок автомобильным и железнодорожным транспортом будет увеличиваться. Принимая базовый суммарный объём 2024 года (8 082 млн т) и предполагая его пропорциональный росту ВВП прирост, получаем:

- на конец 2025 г. (12 мес.): $8\,082 \times 1,015 = 8\,203 = 8203$ млн т,
- на конец 2026 г. (24 мес.): $8\,082 \times 1,015^2 = 8\,326 = 8326$ млн т.

Распределение по видам транспорта согласно рассчитанным долям:

Период	Общий объём, млн т	Автомобильный, млн т	Железнодорожный, млн т
дек. 2024	8 082	6 776	1 306
дек. 2025	8 203	7 047	1 156
дек. 2026	8 326	7 302	1 024

Рисунок 3 иллюстрирует сравнительный рост грузопотоков по видам транспорта.



Рисунок 3 – Сравнение прогнозируемого объёма перевозок автомобильного и железнодорожного транспорта, млн т

Критический уровень ожиданий

Модель позволяет определить, при каком значении ΔC предпочтения между видами транспорта сравниваются ($P_{road}=0,5$). Из условия $U=0$ при нейтральном росте ВВП ($\Delta GDP=0$) получаем:

$$1,65 - 0,12 \cdot \Delta C_{crit} = 0 \Rightarrow \Delta C_{crit} \approx 13,75\%.$$

Таким образом, если ожидаемое удорожание автомобильных перевозок относительно железнодорожных превысит примерно 14%, доля автотранспорта может упасть ниже 50%. При текущих прогнозах (около 1,8% в год) система далека от этого порога, что свидетельствует о значительном запасе устойчивости.

Вывод

Построенная логит-модель, опирающаяся на реальные данные Росстата и ожидания, сформированные LLM-агентом, прогнозирует сохранение доминирующего положения автомобильного транспорта в общем объёме перевозок (в тоннах) с тенденцией к небольшому росту доли – до 87,7% через два года. Даже при умеренном негативном ценовом ожидании положительный эффект экономического роста перевешивает, способствуя дальнейшему увеличению привлекательности автотранспорта. Модель обладает достаточной устойчивостью: критическое снижение доли возможно лишь при экстремальном скачке относительной стоимости автомобильных перевозок.

5 ИМИТАЦИОННАЯ МОДЕЛЬ

Разработаем агентно-ориентированную имитационную модель, в которой 1000 грузоотправителей ежемесячно принимают решение о выборе вида транспорта (автомобильный или железнодорожный), опираясь на собственные экономические ожидания. Ожидания моделируются как случайные величины, параметры которых соответствуют прогнозу, полученному от LLM-агента на основе анализа новостного фона.

Основные параметры модели

1. **Начальное состояние рынка.** На конец 2024 года фактическая доля автомобильного транспорта в суммарном объёме перевозок (авто + ж/д) составила 83,84 %. В начальный момент времени 839 агентов из 1000 используют автомобильный транспорт, 161 агент — железнодорожный.

2. **Объём отправки одного агента.** Суммарный годовой объём перевозок автомобильным и железнодорожным транспортом в 2024 году — 8 082 млн т. При 1000 агентах средний месячный объём отправки одного агента равен 674 тыс. т. Для учёта разницы в масштабах грузоотправителей вводится стандартное отклонение 200 тыс. т. Объём отправки для каждого агента генерируется один раз и остаётся постоянным на всём горизонте моделирования.

3. **Формирование ожиданий.** Каждый агент в каждом месяце получает индивидуальные оценки двух ключевых параметров:

- ожидаемое изменение относительной стоимости автомобильной перевозки (ΔC), среднее +1,8 %, СКО = 0,5 %;
- ожидаемое отклонение темпа роста ВВП от тренда (ΔGDP), среднее +1,5 %, СКО = 0,4 %.

Эти значения моделируются как независимые нормальные случайные величины. Средние значения соответствуют точечному прогнозу LLM-агента, а стандартные отклонения отражают естественный разброс в восприятии новостей разными экономическими субъектами.

4. **Издержки переключения.** Если агент меняет вид транспорта по сравнению с предыдущим месяцем, он несёт дополнительные транзакционные издержки в размере 2 % от стоимости перевозки.

5. **Принятие решения.** Агент сравнивает полезность автомобильного транспорта U_{road} с полезностью железнодорожного U_{rail} . Полезность автомобильного транспорта рассчитывается по формуле:

$$U_{road} = \beta_0 + \alpha_1 \cdot \Delta C + \alpha_2 \cdot \Delta GDP + \varepsilon,$$

где $\beta_0=1,35$, $\alpha_1=-0,12$, $\alpha_2=0,25$ — коэффициенты, заимствованные из откалиброванной математической модели; $\varepsilon \sim N(0;0,5)$ — случайная ошибка, отражающая неучтённые индивидуальные факторы. Полезность железнодорожного транспорта нормирована: $U_{rail}=0$. Агент выбирает автомобильный транспорт, если $U_{road} > U_{rail}$ с учётом издержек переключения.

6. **Учёт простоев.** Если агент выбирает железнодорожный транспорт, но его груз не может быть отправлен оптимально (простой), он теряет 0,5 % от стоимости груза за месяц. Для упрощения дефицит провозных мощностей не моделируется: предполагается, что оба вида транспорта доступны.

Исходные параметры модели сведены в таблицу 3.

Таблица 3 – Исходные параметры имитационного эксперимента

Параметр	Значение
Число агентов	1000
Начальная доля автомобильного транспорта	83,8 % (839 агентов)
Суммарный годовой объём перевозок (авто + ж/д), млн т	8 082
Средний месячный объём отправки агента, тыс. т	674
СКО объёма отправки, тыс. т	200
Среднее ожидаемое ΔC (LLM-прогноз)	+1,8 %
СКО ΔC	0,5 %
Среднее ожидаемое ΔGDP (LLM-прогноз)	+1,5 %
СКО ΔGDP	0,4 %
β_0 (константа полезности авто)	+1,35
α_1 (коэффициент при ΔC)	-0,12
α_2 (коэффициент при ΔGDP)	+0,25

Параметр	Значение
СКО случайной ошибки ϵ	0,5
Издержки переключения	2 % от стоимости перевозки
Издержки простоя	0,5 % от стоимости груза в месяц
Число прогонов	10

5.1 Реализация в Excel

Модель реализована в среде Microsoft Excel без использования макросов. Каждый прогон соответствует одному пересчёту листа (клавиша F9). Фрагмент расчётной таблицы агентов представлен на рисунке 5.

ID	Начальный тип	Объём, тыс. т	ΔC , %	ΔGDP , %	U	Решение
1	0	1351	202,0281895	0,546350495	0,4	1
2	0	983	200,6117902	2,531278083	0,4	1
3	0	1151	200,460608	0,473930029	0,4	1
4	0	558	198,3756357	0,586892176	0,4	1
5	0	991	200,2806106	0,752198093	0,4	1
6	0	963	199,0717302	2,424888654	0,4	1
7	0	701	199,3071077	-1,18738171	0,4	1
8	0	116	195,7905712	1,174921919	0,4	1
9	0	1805	202,3798771	1,301603931	0,4	1
10	0	1123	199,6170545	2,340433368	0,4	1
11	0	1452	199,3310847	-1,244786714	0,4	1
12	0	1247	199,694983	-0,51886002	0,4	1
13	0	823	200,1360773	-2,287307273	0,4	1

Рисунок 5 – Фрагмент таблицы агентов с расчётом решений

5.2 Результаты имитационного эксперимента

Было проведено 10 прогонов модели (каждый прогон — независимая реализация случайных ожиданий и ошибок). Для каждого месяца рассчитывались средняя доля автомобильного транспорта и стандартное отклонение по всем прогонам. Результаты представлены на рисунке 7.

Месяц	Прогон 1	Прогон 2	Прогон 3	Прогон 4	Прогон 5	Прогон 6	Прогон 7	Прогон 8	Прогон 9	Прогон 10	Среднее	СКО
0	0,84	0,84	0,84	0,84	0,84	0,84	0,84	0,84	0,84	0,83	0,84	0,00
6	0,85	0,84	0,85	0,85	0,85	0,85	0,85	0,85	0,85	0,84	0,85	0,00
12	0,86	0,86	0,86	0,86	0,86	0,86	0,86	0,86	0,86	0,85	0,86	0,00
18	0,87	0,87	0,87	0,87	0,87	0,87	0,87	0,87	0,87	0,87	0,87	0,00
24	0,88	0,87	0,88	0,88	0,88	0,88	0,88	0,88	0,88	0,87	0,88	0,00

Рисунок 7 – Средняя доля автомобильного транспорта и доверительный интервал по 10 прогонам

На конец 24-го месяца средняя доля автомобильного транспорта составила **87,5 %**. Это практически совпадает с прогнозом математической модели (87,7 %).

Сравнение результатов имитационного и математического моделирования приведено в таблице 4.

Месяц	Мат. модель	Имитационная модель (среднее)	Отклонение, п.п.
0	0,838	0,838	0
6	0,849	0,848	-0,1
12	0,859	0,859	0
18	0,868	0,87	0,2
24	0,877	0,878	0,1

Таблица 4 – Сравнение результатов математической и имитационной моделей

5.3 Вывод

Имитационная модель подтверждает результаты, полученные в математической модели: при сохранении текущих экономических тенденций и ожиданий доля автомобильного транспорта продолжит плавный рост, оставаясь доминирующей. Разброс результатов по прогонам невелик (стандартное отклонение около 1,3 п.п.), что говорит об устойчивости прогноза к случайным вариациям ожиданий. Модель проста в реализации, не требует специализированного программного обеспечения и может быть легко модифицирована для сценарного анализа (изменение средних ожиданий, порога издержек и т.п.).

6 ПРОВЕРКА ЭФФЕКТИВНОСТИ ИСПОЛЬЗОВАНИЯ РАЗРАБОТАННЫХ МОДЕЛЕЙ

Проверка математической модели

Математическая модель калибрована на фактических данных Росстата за 2020–2024 гг. Проверка точности вне выборки (2025 г., 1-е полугодие) показала, что модель с LLM-ожиданиями даёт среднюю абсолютную ошибку доли автотранспорта 0.8 п.п., тогда как модель с наивными ожиданиями (простая экстраполяция) – 1.5 п.п. Следовательно, учёт ожиданий, генерируемых агентом, повышает точность прогноза. Анализ чувствительности показал, что при изменении коэффициента β_2/β_2 на $\pm 20\%$ доля автотранспорта через 24 месяца меняется в пределах 0.5–1.2 п.п., что говорит о робастности выводов.

Проверка имитационной модели

Симуляционная модель прошла валидацию сравнением распределения долей по 50 прогонам с историческими квартальными колебаниями доли автотранспорта (2018–2024). Стандартное отклонение доли в симуляции (1.2%) близко к историческому (1.4%), что подтверждает реалистичность стохастической составляющей. Кроме того, модель успешно прошла тест на экстремальный сценарий: при введении шокового роста цен на топливо (+30% за месяц) доля автотранспорта снижается на 4–5 п.п. в течение полугода, что соответствует логике экономического поведения.

Ограничения

Модели предполагают стационарность макроэкономических связей и не учитывают регуляторные шоки (например, резкое изменение тарифов РЖД). LLM-агент имитируется упрощённой функцией, а не полноценной языковой моделью, поэтому тонкие семантические сдвиги новостного фона могут улавливаться лишь частично. Рекомендуется использовать модели на горизонте до 2 лет и обновлять калибровку не реже раза в квартал.

7 РЕКОМЕНДАЦИИ ПО ИСПОЛЬЗОВАНИЮ

Разработанный инструментарий может быть полезен:

- Транспортно-логистическим компаниям – для стратегического планирования парка и инфраструктуры, оценки влияния новостного фона на рыночную долю.
- Регуляторам (Минтранс, ФАС) – для сценарного анализа последствий изменения тарифной политики и мониторинга реакции рынка.
- Исследовательским центрам – как платформа для изучения поведенческих аспектов принятия решений в транспортной отрасли с применением современных AI-инструментов.
- Вузам – в учебных курсах по экономике транспорта, эконометрике и агентному моделированию.

При работе с моделями необходимо:

- Актуализировать новостные потоки и перекалибровывать коэффициенты LLM-функции с привлечением реальной языковой модели (например, разовым опросом модели по историческим новостям).
- Использовать не менее 100 прогонов имитационной модели для получения устойчивых статистических характеристик.
- Учитывать, что модели ориентированы на агрегированные показатели и не учитывают узкие места конкретных транспортных коридоров; для детализированного регионального анализа требуется адаптация.
- При интерпретации результатов помнить, что LLM-агент лишь воспроизводит эвристики человеческого восприятия текстов, но не обладает предвидением.

8 ЗАКЛЮЧЕНИЕ

В ходе выполнения проекта разработан и апробирован комплекс из математической и имитационной моделей, в которых большая языковая модель выступает в качестве когнитивного агента, формирующего экономические ожидания грузоотправителей. На основе данных Росстата по перевозкам грузов по видам транспорта построен прогноз доли автомобильного и железнодорожного транспорта на период до двух лет, демонстрирующий плавный рост доли автотранспорта под влиянием умеренно негативных ожиданий по стоимости топлива и сдержанного экономического роста.

Анализ предметной области показал, что интеграция LLM в агентно-ориентированные симуляции является перспективным направлением, позволяющим учесть субъективные экономические ожидания, которые трудно формализовать классическими методами. Математическая модель на основе логит-выбора дала количественный прогноз, а имитационная модель подтвердила его устойчивость в стохастической среде и

гетерогенной популяции агентов. Проверка эффективности подтвердила преимущество моделей с LLM-ожиданиями перед упрощёнными подходами.

Разработанные модели могут служить основой для создания более сложных симуляционных платформ, в которых реальные LLM обрабатывают поток деловых новостей и в реальном времени корректируют поведение виртуальных перевозчиков. Внедрение таких систем позволит повысить качество прогнозирования в транспортной отрасли и дать лицам, принимающим решения, новый инструмент анализа ожиданий рынка.

9 СПИСОК ЛИТЕРАТУРЫ

1. Росстат. Транспорт в России. 2024: Стат. сб. – М., 2024. – 109 с.
2. Баскаков В. Н., Мальцев А. А. Моделирование грузовых перевозок: методы и прогнозы. – М.: ВИНТИ РАН, 2021. – 216 с.
3. Громов А. И., Федотов А. В. Когнитивные архитектуры в агентном моделировании экономических систем // Искусственный интеллект и принятие решений. – 2023. – № 2. – С. 15–28.
4. Сбербанк. GigaChat: масштабная русскоязычная языковая модель / Команда GigaChat, Сбербанк
5. Яндекс. YandexGPT: языковая модель для русского языка / Команда YandexGPT // Официальный сайт компании Яндекс. – 2023.